

Tutto_Misure, 3, 2026

[20.7.26]

Nelle prime due parti di questo articolo, pubblicate nei due numeri precedenti di Tutto_Misure (1, 2026; 2, 2026), abbiamo introdotto per linee generali un *framework* che offre un'interpretazione – fra le varie che sono state proposte – per i concetti di dato e informazione e le loro relazioni. L'interesse è soprattutto di evidenziare la struttura delle relazioni tra le entità in considerazione, per mostrarne la complessità e giustificare così appunto la molteplicità di possibili interpretazioni, e non di mettersi nella posizione normativa di stabilire cosa dovrebbe essere chiamato “dato” e cosa “informazione”. Questi termini saranno usati qui, ma solo per evitare di usare termini semanticamente neutri come “entità-1”, “entità-2”, ..., che renderebbero la lettura meno agevole.

Data la complessità del nostro argomento, è utile un'analisi critica degli argomenti che abbiamo presentato finora.

Dati come elementi di uno spazio di alternative distinguibili in accordo a un criterio

Il punto di partenza – ispirato alla “teoria della comunicazione” di Claude Shannon – è l'idea di considerare che siano dati le entità caratterizzate dall'unica condizione di essere identificate come *elementi di uno spazio di alternative distinguibili* (“è questo, ma avrebbe potuto essere qualcos'altro”). Ne segue la distinzione tra fatti (scriviamo di fatti, ma analogamente potremmo scrivere di eventi, stati di sistemi o processi, ...) e dati. Per esempio, è un fatto che ai capi di un certo resistore ci sia una certa tensione in un certo intervallo in un certo momento, ma tensioni diverse nello stesso intervallo, anche ai capi di resistori diversi in momenti diversi, potrebbero essere trattate come non distinte, e quindi come lo stesso dato.

Dunque si producono dati (i) discriminando fatti in accordo a un criterio e ignorando le altre differenze, (ii) classificando i fatti sulla base di tale criterio in almeno due classi, e (iii) decidendo di trattare ciascuna classe come un dato. Questa situazione può essere descritta come la costruzione di una relazione di equivalenza sul dominio empirico. Due fatti sono equivalenti ai fini della produzione di dati quando le loro differenze sono irrilevanti per il criterio di discriminazione adottato: *non c'è dato senza un criterio di rilevanza*, che stabilisce quali differenze sono considerate da mantenere e quali no (“quali differenze fanno una differenza”, secondo Gregory Bateson) (in questo senso, i dati – sostantivo – non sono interamente dati – participio passato – perché dipendono da un criterio che non è intrinseco ai fatti, pur dipendendo da essi).

Dati come entità astratte

Un certo dato è ottenuto astraendo le differenze non rilevanti da ogni fatto che ai capi di certi resistori ci sia una tensione in un certo intervallo di tensioni: dunque *la relazione tra fatti e dati è una funzione di astrazione*. La condizione che i dati siano ottenuti astraendo dalle differenze considerate non rilevanti di fatti diversi, si formalizza riconoscendo che questa funzione di astrazione è generalmente non iniettiva: fatti diversi possono portare lo stesso dato.

Nella sua forma più primitiva, un dato si ottiene dunque accertando che un certo fatto appartiene a una certa classe di equivalenza di fatti. Per renderne più efficiente il trattamento, ogni classe di equivalenza può essere etichettata. L'usuale scelta – già di Shannon – di chiamare tali etichette “simboli di un alfabeto” (se le classi sono due l'alfabeto potrebbe essere $\{0,1\}$) evidenzia ulteriormente che *i dati sono entità astratte* dal sistema fisico su cui sono portati.

Attraverso una funzione di astrazione, dei fatti vengono trattati come realizzazioni empiriche di dati. Ciò spiega perché, in un processo di acquisizione di dati, un fatto può causalmente condurre alla produzione di un dato, e quindi *dei fatti diventano generatori di dati*. Una funzione di astrazione è dunque innanzitutto uno strumento concettuale per mettere in relazione entità empiriche con entità non empiriche. Ne segue che nel mondo empirico non ci sono dati in quanto dati: ci sono fatti che possono essere scelti come supporto per

dati. In questo senso, una funzione di astrazione è essenzialmente diversa da una funzione di trasduzione, che descrive la conversione di entità empiriche in entità empiriche, per esempio variazioni di temperatura di un corpo in variazioni di volume del corpo stesso. Come vedremo, nella misurazione trasduzione e astrazione sono concatenate.

Una semplice formalizzazione. Dato un dominio X di fatti x confrontabili per un criterio C , è stabilita su X una relazione di equivalenza $\sim_C$ indotta da C . Dato un alfabeto Y di simboli y , una funzione di astrazione a_C basata su C , $a_C: X \rightarrow Y$, è definita come $a_C := s \circ p_C$, dove $p_C: X \rightarrow X/\sim_C$ associa ogni fatto alla sua classe di equivalenza e $s: X/\sim_C \rightarrow Y$, che si assume sia iniettiva, attribuisce a ogni classe un simbolo. Dunque $a_C(x_i) = a_C(x_j)$ se e solo se $x_i \sim_C x_j$.

Dati come entità sintattiche

In accordo alla terminologia di Shannon, i simboli possono essere composti in messaggi, che nel caso più semplice e comune sono successioni di simboli (più generalmente, un messaggio può avere una struttura non lineare, per esempio quella di un grafo o di una matrice: ci limiteremo qui al caso lineare). Dato per esempio l'alfabeto $\{0,1\}$, un messaggio potrebbe essere 1101: lo si può considerare un “dato composto”, formato da una successione di “dati elementari” che sono i simboli dell'alfabeto. Anche 10 e 1011 sono messaggi dello stesso alfabeto, tutti sono formati dagli stessi simboli, eppure sono successioni diverse, e quindi messaggi diversi. Dunque in un messaggio uno stesso simbolo può comparire più volte, e il numero di occorrenze e la loro posizione nella successione sono rilevanti per identificare uno specifico messaggio. Ne concludiamo che trattando di dati è necessario distinguere i simboli, in quanto elementi di un alfabeto, dalle loro occorrenze nei messaggi. È quella che in filosofia si presenta come *la distinzione tra type e token*. Quanti simboli ci sono nel messaggio 1101, dunque? È una domanda ambigua, perché ci sono due simboli-type (0 e 1) ma quattro simboli-token (1, 1, 0, 1), e in particolare tre token del type 1, identificati dalla loro posizione nella successione (è una distinzione concettualmente così importante che la si ritrova in vari contesti, per esempio in ontologia in termini di universali e particolari e nella modellistica object-oriented in termini di classi e oggetti / istanze) (e le cose sono ulteriormente complesse: anche la successione 1101 in quanto tale è a sua volta un type, che può avere molteplici occorrenze / token, per esempio quando viene scritta più volte: il processo di astrazione può essere ripetuto, con astrazioni progressive).

La composizione di simboli in messaggi *introduce una dimensione sintattica*: un sistema di dati comprende non soltanto uno spazio di simboli elementari, ma anche delle regole che stabiliscono come tali simboli possono essere combinati in strutture ammissibili. In logica e matematica lo si descrive in termini di “formule ben formate”: $1+1$ e $11+$ sono due messaggi / formule prodotti dallo stesso alfabeto, ma solo il primo è ben formato in accordo alle regole sintattiche dell'aritmetica. Sono comunque entrambi dati, o è un dato solo un messaggio ben formato, e quindi $1+1$ è un dato ma $11+$ non lo è? La risposta è convenzionale, e questo è l'esempio di una delle ambiguità a proposito del nostro argomento.

La presenza di una sintassi ci consente di fare un ulteriore passo, per introdurre un concetto di invarianza strutturale. Vediamolo in azione nel caso del Run-Length Encoding (RLE), un metodo elementare di compressione di dati senza perdita (*lossless*). Per esempio, mediante RLE la successione 1111100011 può essere trasformata in $(1, 5) (0, 3) (1, 2)$, indicando per ogni simbolo il numero delle sue occorrenze consecutive (il fatto che in questo esempio la successione trasformata sia più lunga – in numero di simboli dell'alfabeto – della successione di partenza nostra solo che RLE non è un metodo di compressione sempre efficiente). Le due successioni sono sintatticamente diverse, anche perché sono ottenute da alfabeti diversi – nel secondo sono incluse virgole e parentesi –, e sono tuttavia equivalenti rispetto a una regola che consente di ricostruire integralmente la prima dalla seconda. Di un messaggio è dunque possibile distinguere la struttura sintattica dalle sue rappresentazioni (in accordo a RLE, 1111100011 e $(1, 5) (0, 3) (1, 2)$ sono rappresentazioni diverse di una stessa struttura). Detto altrimenti, *un messaggio è la rappresentazione di una struttura sintattica*, e diversi messaggi possono rappresentare la stessa struttura sintattica.

Una nota su una questione matematica. Una volta introdotta la distinzione fra struttura sintattica e sua rappresentazione, si possono studiare i criteri per minimizzare il numero di simboli impiegati per rappresentare le strutture prodotte da una sorgente di dati. Nel caso in cui sia definita una distribuzione di probabilità sui simboli dell'alfabeto della sorgente, Shannon ha mostrato che l'entropia della distribuzione, $-\sum_i p(x_i) \log(p(x_i))$, è il limite inferiore alla lunghezza media delle rappresentazioni. Quando invece si considera una singola struttura, indipendentemente da una distribuzione probabilistica, la complessità di Kolmogorov ne caratterizza la comprimibilità come lunghezza della più breve descrizione algoritmica capace di generarla.

Dalla sintassi alla semantica: dai dati all'informazione

Finora abbiamo considerato soltanto relazioni interne ai sistemi di dati: relazioni di equivalenza fra fatti, composizione di simboli in messaggi, regole sintattiche, trasformazioni che preservano una struttura. Nessuna di queste relazioni richiede che i dati si riferiscano a qualcosa di esterno al sistema simbolico, che rimane un'entità esclusivamente sintattica, senza significati. Una formula può essere infatti ben formata anche senza che le venga attribuito un significato, tantomeno un valore di verità (a differenza di $1+1$, $1+1$, $1+1=3$, e $1+1=2$ sono tutte formule ben formate: la prima non è né vera né falsa, la seconda è falsa, e solo la terza è vera). Le strutture sintattiche possono essere però interpretate come riferite a entità (come oggetti, proprietà, stati di cose, eventi, o processi) appartenenti a un qualche dominio, introducendo così una relazione semantica che consente finalmente di distinguere il dato dall'informazione: *un dato diventa informazione quando è interpretato come riferito a qualcosa*.

Su questa base può essere recuperata la consueta caratterizzazione dell'informazione come dati dotati di significato, purché non la si interpreti come se il significato fosse una sostanza aggiunta ai dati. Il significato è piuttosto una relazione: un messaggio diventa informativo quando, all'interno di un sistema interpretativo, viene messo in relazione con qualcosa che non coincide con la sua struttura sintattica. Parlare di "dati con significato" è dunque un'abbreviazione per parlare di dati interpretati da qualcuno o da qualcosa, in un certo contesto e secondo determinate convenzioni o regole.

Una relazione semantica può essere complessa per almeno due ragioni.

Una prima ragione è che la stessa struttura sintattica può essere interpretata in modi diversi, e quindi veicolare informazioni diverse, e strutture sintattiche diverse possono essere equivalenti dal punto di vista semantico, e quindi veicolare la stessa informazione. I dati costituiscono il supporto sintattico dell'informazione, ma non si identificano con essa: la semantica introduce un'interpretazione dei dati.

Una seconda ragione della complessità delle relazioni semantiche è che l'interpretazione può essere iterata, e il risultato di un'interpretazione può diventare una struttura sintattica da interpretare ulteriormente. Nel codice Morse, per esempio (con differenze minori quanto segue vale anche per altri codici "di basso livello" come il codice ASCII / Unicode), certi stati fisici e certe durate temporali vengono dapprima astratti nei simboli punto, linea, e pausa; le successioni ben formate di tali simboli vengono quindi interpretate come caratteri alfanumerici (la successione punto, linea, pausa significa la lettera "a", la successione linea, punto, punto, pausa significa la lettera "b", e così via). A questo punto, i caratteri così ottenuti possono essere trattati come simboli, componibili in particolari successioni ben formate che sono le parole di una certa lingua, che come tali hanno un significato, per come specificato in un vocabolario di quella lingua. Alcune successioni ben formate di parole della lingua sono poi interpretate come frasi dotate di significato.

Il percorso che abbiamo seguito può essere ricostruito attraverso quattro passaggi:

- mediante astrazione (da fatti a dati) fatti differenti vengono trattati come realizzazioni dello stesso dato attraverso l'applicazione di relazioni di equivalenza;
- mediante composizione (da dati-simboli a dati-messaggi) le occorrenze dei dati vengono organizzate in messaggi dotati di struttura sintattica;
- ancora mediante astrazione (questa volta da messaggi a strutture sintattiche) messaggi differenti vengono riconosciuti come rappresentazioni equivalenti di una stessa struttura;
- infine, mediante interpretazione (da strutture sintattiche a informazione-referenti) le strutture sintattiche

vengono poste in relazione con entità di un dominio e acquisiscono significato, e questa relazione significante-significato può essere iterata e diventare così sempre più complessa.

Ciò mostra che la tradizionale dicotomia fra dato e informazione, spesso presentata sostenendo che si ottiene informazione aggiungendo significato ai dati, emerge da una successione di trasformazioni concettualmente distinte.

Con ciò, siamo finalmente pronti a interpretare la misurazione – fra mondo empirico, dati, e informazione – alla luce di questo framework. Sarà il nostro prossimo passo.